



ESTACIÓN 10

Ciberseguridad

De POC funcional a pentesting asistido con Shannon

Hoy aterrizamos seguridad en una demo ejecutable

4

actos para pasar de marco
mental a evidencia

Entender por qué producción
cambia el riesgo.

Convertir superficies en
checklist, backlog y reporte.

Usar OWASP y controles para
decidir qué mirar.

Ejecutar Shannon contra local o
staging aislado.

Cierre esperado: hallazgos, PoCs, fixes o tareas verificables.

Seguridad: De POC a Producción - El Viaje a la Resiliencia



Las superficies ordenan la conversación

Checklist: qué puede fallar.

Backlog: qué necesita dueño, fix y validación.

Reporte: dónde queda evidencia y riesgo residual.

Scope de demo: qué tocará Shannon y qué queda fuera.

El mapa evita que seguridad se convierta en una lista de herramientas sin relación con el producto.

Mapa de Superficies de Riesgo

Índice Operativo: Checklist, Backlog y Reporte

INFRAESTRUCTURA Y PLATAFORMA




Nube, red, OS, contenedores, runtime

EDGE Y EXPOSICIÓN



DNS, CDN, WAF, reverse proxy, API gateway

SERVICIOS Y APLICACIÓN



Código, configuración, APIs, feature flags

IDENTIDAD Y ACCESO



Humanos, servicios, agentes, llaves, IAM, RBAC

DATOS



DBs, objetos, colas, logs, RAG, retención

SISTEMA DE IA



Modelo e inferencia, prompts, contexto, agentes y herramientas, evals y guardrails

SDLC Y SUPPLY CHAIN



Dependencias, CI/CD, IaC, imágenes, firmas

OBSERVABILIDAD Y RESPUESTA



Auditoría, detección, IR



Heurística de Priorización (POC a Producción)



ENFOQUE EN IMPACTO IRREVERSIBLE

↓ Exfiltración ↓ Ejecución Remota ↓ Escalamiento de Privilegios ↓ Destrucción de Datos

EMPEZAR
AQUÍ



PRIORIDAD: AMPLIFICADO CON IA

Agencia, Herramientas, Contexto y Supply Chain



OWASP ayuda a nombrar el riesgo y diseñar pruebas

Web: aplicación, API, auth, configuración, logging y supply chain.

LLM: instrucciones, datos, output handling, agency y consumo.

Agentic: herramientas, identidad, memoria, contexto y canales entre agentes.

En la demo, cada hallazgo se liga a una categoría y a una verificación.

Frameworks y taxonomías: OWASP y Seguridad Avanzada

1) OWASP Top 10 Web Application Security Risks 2025

Como mapa base para aplicaciones y APIs

-  **A01:2025** Broken Access Control
-  **A02:2025** Security Misconfiguration
-  **A03:2025** Software Supply Chain Failures
-  **A04:2025** Cryptographic Failures
-  **A05:2025** Injection
-  **A06:2025** Insecure Design
-  **A07:2025** Authentication Failures
-  **A08:2025** Software or Data Integrity Failures
-  **A09:2025** Security Logging and Alerting Failures
-  **A10:2025** Mishandling of Exceptional Conditions

2) OWASP Top 10 for LLM Applications 2025

Taxonomía específica de riesgos en apps con LLM

-  **LLM01:2025** Prompt Injection
-  **LLM02:2025** Sensitive Information Disclosure
-  **LLM03:2025** Supply Chain
-  **LLM04:2025** Data and Model Poisoning
-  **LLM05:2025** Improper Output Handling
-  **LLM06:2025** Excessive Agency
-  **LLM07:2025** System Prompt Leakage
-  **LLM08:2025** Vector and Embedding Weaknesses
-  **LLM09:2025** Misinformation
-  **LLM10:2025** Unbounded Consumption

Lectura práctica para ingeniería: estos riesgos suelen colapsar en **4 controles estructurales**

-  Separación estricta entre instrucciones y datos (y etiquetado de contenido no confiable)
-  Validación y "gating" determinístico de outputs antes de ejecutar acciones
-  Privilegios mínimos y "least agency" para herramientas y side effects
-  Presupuestos y límites (tokens, costo, rate, tiempo) para evitar consumo no acotado

3) OWASP Top 10 for Agentic Applications 2026

Para sistemas con agentes que planifican y actúan con herramientas

-  **ASI01** Agent Goal Hijack
-  **ASI02** Tool Misuse and Exploitation
-  **ASI03** Identity and Privilege Abuse
-  **ASI04** Agentic Supply Chain Vulnerabilities
-  **ASI05** Unexpected Code Execution (RCE)
-  **ASI06** Memory & Context Poisoning
-  **ASI07** Insecure Inter-Agent Communication
-  **ASI08** Cascading Failures
-  **ASI09** Human-Agent Trust Exploitation
-  **ASI10** Rogue Agents

Traducción inmediata a hardening del arnés

-  Permisos de herramientas
-  Identidad de agentes
-  Canales inter-agente
-  Memoria/contexto persistente

Los controles definen qué puede hacer el agente

Prevención: reducir rutas de abuso antes de exponer el sistema.

Detección: logs y alertas para saber qué pasó.

Respuesta: triage, contención y recuperación.

Guardrails: permisos mínimos, credenciales separadas y aprobación para side effects altos.

Controles: de POC a producción



A. Prevención (qué endurecer primero)

POC Producción




INFRA Y PLATAFORMA

Baselines de hardening del runtime: imágenes mínimas, usuarios no root, capabilities mínimas, aislamiento, parches y actualización; IaC con defaults seguros y revisión automatizada



EDGE Y EXPOSICIÓN

TLS bien configurado, headers, rate limiting, WAF donde aplique, y logs de borde; Política de CORS y endpoints públicos explícitos



SERVICIOS Y APLICACIÓN

Autorización como política (A01) y no como condicionales dispersos; Validación de input, encoding, contra inyecciones (A05)



IDENTIDAD Y ACCESO

MFA, rotación, separación de roles, Para agente: agente y por herramienta, scopes mínimos y expiración corta



DATOS

Clasificación simple (PII, secretos, internos, públicos), retención, cifrado en tránsito y reposo, y auditoría de acceso Para RAG: higiene de fuentes y límites de acceso, output handling determinístico (LLM05), y políticas contra prompt injection (LLM01)




SUPPLY CHAIN

- Gestión de dependencias (SCA), bloqueo por políticas, SBOM, firma y verificación cuando aplique
- Controles para "agentic supply chain": prompts, skills, plugins, MCP servers, tool adapters



B. Detección y respuesta (cuando algo falla)




LOGS ÚTILES

Log file with identity trace, request ID, decisions, herramientas, changes



ALERTAS ACCIONABLES

Con severidad y runbooks



IR BÁSICO

Triage, contención, erradicación, recuperación, postmortem



C. Continuidad y resiliencia (BCP, BIA, DRP)




BIA PRIORITARIA

Para priorizar sistemas críticos y dependencias



DRP CON OBJETIVOS

RPO, RTO, WRT, MTD



INMUTABILIDAD DE EVIDENCIA

Inmutabilidad y aislamiento de logs y evidencia cuando aplique



EJERCICIOS Y COMUNICACIÓN

Ejercicios de recuperación y canales de comunicación alternos

IA aplicada a seguridad



1) "Security copilots" para hardening, sin crear nuevos riesgos

patrón recomendado: agentes para acelerar análisis y ejecución repetible, con guardrails (REDUCIR BLAST RADIUS)

Guardrails mínimos del arnés:



Allowlist explícita de herramientas y comandos, contra inyecciones



Separación de credenciales por entorno (dev, staging, prod) y por rol.



Aprobación humana para side effects altos (borrar datos, rotar llaves, cambiar IAM, desplegar).




Logging estructurado del "agentic loop": objetivo, plan, comandos, diffs, outputs, verificación.



2) SAST con agentes, guiado por OWASP


Flujo típico:



1. Generar checklist de categorías OWASP aplicables (web, API, auth, crypto, supply chain).



2. Ejecutar **SAST** (Semgrep o CodeQL) y scanning de secretos.



3. **Triage** agencial: agrupar hallazgos por riesgo, impacto, explotabilidad.



4. Proponer **fixes** con pruebas de regresión. y dependencias



5. Generar "**Security Backlog**" con criterios de aceptación y comandos de verificación.



3) Pentesting asistido por IA (mención breve y responsable)

Shannon (KeygraphHQ) – es un pentester autónomo que busca vectores y ejecuta exploits reales para probar explotabilidad en apps web.

Uso pedagógico en esta clase: entender cómo cambia el juego cuando el atacante también automatiza exploración y explotación. Por qué eso hace valiosos los controles de autorización, segmentación, límites, y observabilidad.

Shannon prueba explotabilidad con conocimiento del código

Entrada Repo fuente y URL de la app viva.

Método Análisis white-box más explotación dinámica.

Salida Hallazgos con PoC reproducible.

Regla Solo local o staging aislado.

Busca vectores desde el código.

Usa browser automation y herramientas CLI.

Descarta hipótesis sin exploit funcional.

Puede causar side effects. El entorno importa.

Del repo a un hallazgo accionable

```
npx @keygraph/shannon setup  
npx @keygraph/shannon start -u http://localhost:3000 -r /path/to/repo
```

Target aislado + datos sintéticos



Shannon con scope explícito



PoC, impacto y ruta



Fix o tarea verificable

Un hallazgo sirve cuando cambia el backlog

¿Hay PoC funcional?

¿Qué activo o permiso queda comprometido?

¿Qué categoría OWASP describe el fallo?

¿Qué test o comando comprueba el fix?

¿Qué guardrail habría limitado el daño?

Decisión humana: severidad, owner, fix, verificación y cierre.

Reporte de seguridad del producto

- ☐ Top 5 riesgos: impacto, evidencia y prioridad.
- ☐ Mapa de superficies: qué se revisó y qué queda fuera.
- ☐ Hallazgos: severidad, PoC, fix y verificación.
- ☐ Controles: prevención, detección, respuesta y guardrails agenciales.
- ☐ Roadmap: quick wins, mediano plazo y cambios estructurales.

Seguridad madura cuando el riesgo termina en evidencia y trabajo verificable.